



Ergebnisse: Informatik

Im Fach Informatik hatten die KI-Systeme größere Schwierigkeiten, konsistente Ergebnisse zu liefern. Teilweise erkannten sie nicht einmal, dass eine Implementierung fehlerhaft war.



Verteilung für Bewertung BubbleSort



Notenverteilung korrekte vs. inkorrekte Implementierung

Fazit

LLMs können als Unterstützung für Feedback und Bewertung interessant sein, sind aber noch nicht zuverlässig genug für eine eigenständige, faire und konsistente Benotung. Besonders kritisch sind:

- schwankende Konsistenz,
- Modellunterschiede,
- starke Beeinflussbarkeit durch Beispiele,
- schwierige Bewertung in technischen Aufgaben.

Quellen und Materialien



Website



GitHub Repo

Literatur

- [1] Klaus Mainzer und Reinhard Kahle. *Grenzen der KI : theoretisch, praktisch, ethisch*. German. Berlin, Germany, 2022. URL: <https://search.ebscohost.com/login.aspx?direct=true&scope=site&db=nlebk&db=nlabk&AN=3311231>.
- [2] Ashish Vaswani u. a. *Attention Is All You Need*. 2023. arXiv: 1706.03762 [cs.CL]. URL: <https://arxiv.org/abs/1706.03762>.

LLMs als Bewertungs- und Feedbacktool in Schulen


Vor- und Nachteile von KI-gestützter Bewertung

Lukas Moritz

Institute für Bildungswissenschaften

Modul 4: CapStone

KI-gestütztes Feedback in der Schule



KI-generiert

Ziele

- Welchen Einfluss hat der Input auf den Output?
- Wie kann der Output verarbeitet werden?
- Wie konsistent sind LLMs?
- Existieren mögliche Gefahren?

Untersuchte Bereiche

- **Fächer:** Deutsch, Informatik, Gemeinschaftskunde
- **Modelle:** ChatGPT, Gemini, DeepSeek, Grok (nur Deutsch)
- **Vergleich:** Bewertung ohne Kontext, mit Beispiel und mit Kontext

Methode

Es wurden standardisierte Inputs an die LLMs übergeben. Für jedes Fach wurden passende Aufgaben verwendet:

- Deutsch: Gedichtinterpretation
- Informatik: BubbleSort-Aufgabe
- Gemeinschaftskunde: zwei Erörterungen


Zusätzlich erhielten die Modelle ein Bewertungsraster samt Output-Vorlage.

Ergebnisse: Konsistenz

Die Untersuchung zeigt, dass LLMs nur eine geringe Konsistenz aufweisen. Zwar sind die Bewertungen oft ähnlich, die einzelnen Bewertungsraster verändern sich aber deutlich.

Außerdem war die Wahl des Modells entscheidend:


- ChatGPT und Gemini bewerteten im Schnitt besser als DeepSeek.
- Beispiele beeinflussen die Bewertung deutlich.
- Auch Kontext wie Geschlecht oder Herkunft hatte nur geringe Effekte.




Heatmap für Deutsch (kalkuliert über alle Inputs)

Ergebnisse: Kontext


Bei der Auswertung konnte kein direkt erkennbarer Bias festgestellt werden. Die zusätzliche Hinzugabe von Kontext, etwa Geschlecht oder Migrationshintergrund, zeigte nur geringe Auswirkungen.



Kein Kontext vs. Geschlecht männlich/weiblich



Kein Kontext vs. Migrationshintergrund



Kein Kontext vs. Keine Recht/Zeichensetzungsfehler