

LLMs als Bewertungs- und Feedbacktool in Schulen und ihre Vor- und Nachteile

Lukas Moritz

CapStone Seminar Schulpraxis Monika Buhl Mo. 14 Uhr Insitute für Bildungswissenschaften Universität Heidelberg Prüfer*innen: Monika Buhl, Louisa Beisel, Anja Lintner, Sascha Lieneweg, Klaus Wild

Ziele

- Welchen Einfluss hat der Input auf den Output?
- Wie kann der Output verarbeitet werden?
- Wie konsistent sind LLMs?
- Existieren mögliche Gefahren?

Einleitung

KI-Systeme, die das Leben von Menschen vereinfachen sollen, existieren bereits seit vielen Jahren. Hubert Dreyfus schrieb bereits im Jahr 1972 ein Buch darüber was Computer nicht können und nutze bereits damals den Begriff Künstliche Intelligenz. Damals bezog er sich auf etwas was heutzutage als “symbolische KI”[1]. Seit dem her sind viele Jahre vergangen, in denen sich zeigte, dass sich vieles ändern kann. 2017 veröffentlichten acht Mitarbeiter von Google das Paper “Attention is all you need”[2]. Dieses Paper befasst sich mit Transformern und wie diese parallel eingesetzt werden können. Dies war ein Meilenstein in der Generativen KI Entwicklung und ermöglichte es OpenAI bereits 2022 den ersten **Generative Pre-trained Transformer** in Form von ChatGPT vorzustellen.



Seit ChatGPT auf der Bildfläche aufgetaucht ist, sind **Large Language Models** nicht mehr aus dem Lebensalltag wegzudenken. Mittlerweile werden diese Systeme auch verstärkt in Bildungseinrichtungen eingesetzt. In Deutschland gibt es dafür das KI-System AIS.chat (ehemals Telli), welches in der Schule sowohl zur Unterrichtsvorbereitung, als auch im Unterricht selbst eingesetzt werden kann



Da KI immer mehr in der Schule Anklang findet soll in diesem Projekt geklärt werden, ob KI auch als sinnvolles Feedback-Tool fungieren kann und welche Vor- und Nachteile damit verbunden sind.

Planung

- Untersuchung von drei Fächern
 - Deutsch
 - Informatik
 - Gemeinschaftskunde
- Genutzt wurden drei (vier) LLMs
 - ChatGPT
 - Gemini
 - DeepSeek
 - Grok (nur Deutsch)

Untersucht wurde auf:

- 1 Bewertung ohne Kontext
 - Rechtschreibfehler
 - Falsche Implementation
- 2 Bewertung mit Beispiel
- 3 Bewertung mit Kontext
 - Geschlecht
 - Herkunft

Methode

Zur Untersuchung des Projekts wurden mehrere Inputs erstellt, welche an die LLMs übergeben wurde. Hierbei waren alle Inputs nach demselben Schema erstellt und enthielten nur kleine Änderungen für die jeweils zu untersuchenden Bereiche. Für das Fach Deutsch wurde hierbei eine Gedichtinterpretation zur Bewertung genutzt, in Informatik eine Aufgabe zu BubbleSort und in Gemeinschaftskunde zwei Erörterungen. Zusätzlich wurde den LLMs ein Bewertungsraster samt Output-Vorlage mitgeben.

Zusammenfassung

direkt erkennbare Bias der KI erkannt werden. Darüber hinaus scheint auch die zusätzliche Hinzugabe von Kontext, wie das Geschlecht oder den Migrationshintergrund, nur eine geringe Auswirkung zu haben.




Abbildung 2: Kein Kontext vs. Geschlecht männlich/weiblich

Im Fach Informatik haben es die KI-Systeme deutlich schwieriger ein konsistentes Ergebnis zu liefern. Hierbei liefern sie zum Teil keinerlei konsistenten Ergebnisse und erkennen auch stellenweise nicht, dass die Implementation nicht funktioniert.




Abbildung 3: Verteilung für Bewertung BubbleSort




Abbildung 4: Notenverteilung korrekte vs. inkorrekte Implementation



WebSite



GitHub Repo

Flyer mit vollständige Quellenangabe im GitHub Repo

Ergebnisse für Konsistenz




Abbildung 1: Heatmap für Deutsch (kalkuliert über alle Inputs)

Zusammenfassung

Die Untersuchung hat ergeben, dass KIs eine geringe Konsistenz aufweisen, ihre Bewertungen sind zwar oft gleich, aber die einzelnen Bewertungsraster verändern sich stark. Des Weiteren ist die Wahl des Modells entscheidend für die Bewertung, ChatGPT und Gemini haben im Schnitt besser bewertet als DeepSeek. Darüber hinaus lassen sich alle KIs durch die gegebenen Beispiele beeinflussen, wobei ein negatives Beispiel, welches jedoch befriedigend bewertet, wurde die KI dazu verleitet die Bewertung zu verschlechtern. Bei der Auswertung der Daten konnte keine

LLMs als Bewertungs- und Feedbacktool in Schulen und ihre Vor- und Nachteile

Lukas Moritz

CapStone Seminar Schulpraxis Monika Buhl Mo. 14 Uhr Insitute für Bildungswissenschaften Universität Heidelberg Prüfer*innen:
Monika Buhl, Louisa Beisel, Anja Lintner, Sascha Lieneweg, Klaus Wild

References

- [1] Klaus Mainzer and Reinhard Kahle. *Grenzen der KI : theoretisch, praktisch, ethisch*. German. Berlin, Germany, 2022. URL: <https://search.ebscohost.com/login.aspx?direct=true&scope=site&db=nlebk&db=nlabk&AN=3311231>.
- [2] Ashish Vaswani et al. *Attention Is All You Need*. 2023. arXiv: 1706.03762 [cs.CL]. URL: <https://arxiv.org/abs/1706.03762>.